

Diagnóstico operacional

Caso técnico Rappi — Módulo 1

Dataset: panel 30 días $\times$ 24 h $\times$ 14 zonas (10 080 filas)

20 de marzo de 2026

Resumen de hallazgos (máx. 1 página)

Patrones. La **saturación** (ratio $> 1,8$) representa el **5,09 %** del panel. Se concentra en franjas **12–14 h** (picos de conteo: 14h, 13h, 12h) y en la tarde (**19–21 h**). Por zona, el mayor número de observaciones en saturación aparece en *San Nicolás*, *Santiago*, *MTY_Guadalupe*, *Carretera Nacional* y *Mitras Centro*. La **precipitación** se asocia al ratio con correlación de Pearson **0,32** con **ratio**; en un MCO $\text{ratio} \sim \text{PRECIPITATION_MM} + \text{HOURL} + \text{ZONE}$, el coeficiente marginal es **+0,081** puntos de ratio por mm/h adicional (muy significativo). Condicionando el umbral de lluvia: $\mathbb{P}(\text{saturación} \mid \text{precip} > 0,5 \text{ mm/h}) \approx 0,31$ frente a $\mathbb{P}(\cdot \mid \text{resto}) \approx 0,038$ — un factor del orden de $\times 8,2$ en cociente de probabilidades. La sensibilidad marginal a lluvia *por zona* (control por hora) es mayor en *Santiago*, *Carretera Nacional* y *Santa Catarina*. A nivel día, la fracción de celdas saturadas llega hasta **16,7 %** en el peor día; el percentil 75 de esa fracción es **4,7 %**. La correlación Spearman global **EARNINGS–ratio** es débil (**0,08**); con precipitación > 0 el signo se invierte respecto al agregado, coherente con que **incentivos y clima interactúan** (modelo con interacción $\text{EARNINGS} \times \text{PRECIPITATION_MM}$).

Impacto cuantificado en la operación. (1) **Capacidad y pricing en ventanas críticas:** priorizar monitoreo y refuerzo de oferta en **12–14 h** y **19–21 h** ataca la mayor densidad observada de saturación. (2) **Playbook de lluvia:** ante precipitación $> 0,5 \text{ mm/h}$ la probabilidad de celda saturada es **ocho veces** la de condiciones secas; conviene activar reglas de incentivos / cupos diferenciados por zona con mayor β marginal (p.ej. Santiago y Carretera Nacional). (3) **Eficiencia de incentivos:** la relación lineal simple incentivo–ratio es floja; revisar alineación día a día entre **earn medio** y **fracción saturada** (dispersión en P4) evita gastar en días de alto incentivo sin reducir estrés proporcionalmente. (4) **Orden de magnitud:** el ejercicio de sensibilidad (mm/h necesarios para mover el ratio $\sim 0,6$ puntos en el tramo saludable→saturación) ordena zonas por “fragilidad” operativa ante lluvia (figura de sensibilidad).

Alineación geográfica y continuidad con el Módulo 2

El diagnóstico sobre **RAW_DATA** debe referirse a las **mismas zonas operativas** que figuran en **ZONE_INFO** (centroides y **DESCRIPTION**) y en **ZONE_POLYGONS** (polígonos en WKT). En el notebook, una celda dedicada importa `validate_excel_zone_consistency` desde `modulo2_motor_alertas/src/zones.py`: comprueba la coincidencia de nombres entre las tres hojas y cuenta cuántos WKT son parseables. Si un polígono viene **truncado** en Excel ($\sim 32\text{k}$ caracteres), no se usa para el punto de consulta; el Módulo 2 entonces toma **LATITUDE_CENTER** y **LONGITUDE_CENTER** de **ZONE_INFO** (caso empaquetado: dos zonas). La misma validación se ejecuta al **recalibrar** (`export_calibration_from_m1.py`) y al arrancar el motor (`run_alert_engine.py`), con advertencias en consola si hubiera desajustes.

La **calibración** del motor (coeficientes marginales de precipitación por zona, umbrales de alerta, sensibilidad, earnings base) se estima desde **RAW_DATA** con la misma especificación que P3 del notebook ($\text{ratio} \sim \text{PRECIPITATION_MM} + \text{C}(\text{HOURL})$ por zona) y se escribe en `calibration.json`. El motor en

vivo combina ese JSON con el **pronóstico horario** (Open-Meteo, mm/h) en coordenadas obtenidas del polígono (**representative_point**) o, en respaldo, de los centroides anteriores. Opción **-recalibrate** en `run_alert_engine.py`: regenera el JSON desde el Excel antes de consultar la API.

Figuras y notas (notebook 01_diagnostico_operacional.ipynb)

Las figuras se generan en el notebook (misma lógica de ratio, clasificación y modelos) y se guardan en `modulo1_diagnostico/figures/`. A continuación se incluyen las principales para el informe.

P1 — Dónde y cuándo hay saturación. Frecuencia por hora del día y ranking de zonas (top 14) según conteos de filas clasificadas como **saturacion**.




Figura 1: P1: saturación por hora (Monterrey) y por zona.

P3 — Heterogeneidad espacial (lluvia). Coeficiente marginal de precipitación sobre el ratio, con efectos fijos por hora dentro de cada zona.




Figura 2: P3: sensibilidad marginal a precipitación por zona (control por hora).

P4 — Earnings frente a estrés operativo. Cada punto es un día: incentivo medio vs. fracción de celdas en saturación; útil para localizar días con alto estrés y alto (o bajo) incentivo.




Figura 3: P4: dispersión diaria earn vs. fracción saturada.

Sensibilidad (orden de magnitud). Aproximación lineal local: mm/h adicionales asociados a un desplazamiento de ratio $\approx 0,6$ (tramo saludable hacia umbral de saturación), por zona.




Figura 4: Sensibilidad: precipitación necesaria por zona (aprox. lineal).

Notas de interpretación (del notebook). $\text{ratio} = \text{ORDERS} / \text{CONNECTED_RT}$ (si conectados = 0, ratio vacío). Clasificación: **saturacion** ($> 1,8$), **sobre_oferta** ($< 0,5$), **saludable** ($0,9-1,2$), **intermedio** en otro caso. P2 usa MCO con dummies de hora y zona; P3 estima por zona $\text{ratio} \sim \text{precipitación} + \text{hora}$; P5 introduce interacción $\text{EARNINGS} \times \text{precipitación}$ para no interpretar incentivos como efecto puro sin clima.